

**FATEC BAIXADA SANTISTA - FACULDADE DE
TECNOLOGIA - RUBENS LARA**

SISTEMA DE RECOMENDAÇÃO DE FILMES

Aplicação das Métricas TF-IDF e Similaridade de Cosseno

Flávia Barbosa
Ciclo 2 - Ciência de Dados

Santos, SP
Novembro de 2025

Conteúdo

1	Resumo	2
2	Introdução e Fundamentação Teórica	2
2.1	Objetivo do Projeto	2
2.2	Similaridade de Cosseno (<i>Cosine Similarity</i>)	2
2.3	TF-IDF (<i>Term Frequency-Inverse Document Frequency</i>)	2
3	Metodologia	3
3.1	Origem e Adaptação da Base de Dados	3
3.2	Transformação (Filtros e Limpeza)	3
3.3	Preparação da Query e Simetria	4
3.4	Vetorização e Parâmetros	4
3.5	Cálculo da Similaridade	4
4	Análise de Resultados	4
4.1	Teste Aplicado: Perfil de Super-Heróis	4
4.2	Ranking de Recomendação (TOP 5)	4
4.3	Discussão dos Resultados	5
5	Conclusão	5

1 Resumo

Este projeto implementa um Sistema de Recomendação Baseado em Conteúdo utilizando a métrica de **Similaridade de Cosseno** e a técnica de vetorização **TF-IDF**. O objetivo é mapear o perfil de preferência textual do usuário (*Query*) em um espaço vetorial de alta dimensão e calcular sua proximidade angular com uma base filtrada de filmes do TMDb (*The Movie Database*). Após um rigoroso processo de ETL (Extração, Transformação e Carga) e filtragem por qualidade, idioma, duração e data, a base final utilizada para análise contém **30.612 títulos**. O teste aplicado demonstrou a eficácia do modelo em correlacionar perfis complexos ("Filmes de Super-Heróis") com *blockbusters* relevantes do universo cinematográfico.

2 Introdução e Fundamentação Teórica

2.1 Objetivo do Projeto

O principal objetivo deste trabalho é desenvolver e validar um sistema de recomendação de filmes. O sistema deve ser capaz de transformar um perfil de preferência textual fornecido pelo usuário (a *Query*) em um vetor numérico e, subsequentemente, ranquear os filmes mais semanticamente semelhantes em uma grande base de dados, utilizando a distância angular entre os vetores.

2.2 Similaridade de Cosseno (*Cosine Similarity*)

A Similaridade de Cosseno é uma métrica fundamental da Álgebra Linear utilizada para medir o quão parecidas são a **direção** de dois vetores em um espaço multidimensional. No contexto do Processamento de Linguagem Natural (NLP), ela mede a similaridade de conteúdo semântico entre dois documentos, ignorando o tamanho do documento.

A métrica é definida pelo cosseno do ângulo (θ) entre o Vetor da Query (**Q**) e o Vetor do Documento (**D**):

$$\text{Similaridade}(\mathbf{Q}, \mathbf{D}) = \cos(\theta) = \frac{\mathbf{Q} \cdot \mathbf{D}}{\|\mathbf{Q}\| \cdot \|\mathbf{D}\|} \quad (1)$$

Uma Similaridade (**S**) próxima de **1** indica um ângulo θ próximo de 0° , significando alta similaridade. Um **S** próximo de **0** indica baixa similaridade.

2.3 TF-IDF (*Term Frequency-Inverse Document Frequency*)

TF-IDF é a técnica de vetorização que transforma o texto em um formato numérico. Ela pondera a importância de uma palavra em um documento em relação a todo o *Corpus* (a base de dados de filmes). O *Term Frequency* (TF) mede a frequência da palavra no documento, enquanto o *Inverse Document Frequency* (IDF) penaliza palavras que aparecem em muitos documentos, valorizando termos raros e específicos que ajudam a diferenciar o conteúdo. A combinação resulta em vetores que representam a **importância semântica** das palavras.

3 Metodologia

3.1 Origem e Adaptação da Base de Dados

O *Corpus* foi construído a partir do **TMDB Movies Dataset** do Kaggle.

- **Fonte:** TMDB (The Movie Database).
- **Dataset Carregado:** asaniczka/tmdb-movies-dataset-2023-930k-movies.
- **Arquivo Utilizado:** TMDB_movie_dataset_v11.csv.

As colunas carregadas foram: `title`, `overview`, `keywords`, `genres`, `tagline`, `vote_average`, `runtime`, `adult`, `release_date`, e `original_language`.

3.2 Transformação (Filtros e Limpeza)

A Transformação (*T* do ETL) foi crucial para criar um *Corpus* de alta qualidade.

Tabela 1: Filtros Aplicados e Justificativas

Filtro	Condição	Justificativa
Qualidade	<code>vote_average > 6.0</code>	Garante a recomendação de filmes com avaliação média razoável, elevando a qualidade percebida.
Duração	<code>runtime > 60</code>	Remove curtas-metragens e <i>trailers</i> , focando apenas em filmes de longa-metragem (acima de 1 hora).
Relevância Temporal	<code>release_year ≥ 1995</code>	Foca a base em conteúdo mais recente (pós-1995), com maior completude de metadados e relevância atual.
Idioma do Conteúdo	<code>original_language == 'en'</code>	CRUCIAL para o NLP: Alinha o idioma do <i>Corpus</i> com o idioma da <i>Query</i> (<code>english</code>), validando a comparação vetorial do TF-IDF.
Censura	<code>adult == False</code>	Exclui filmes classificados como conteúdo adulto, padronizando a classificação do filme recomendado.

Após os filtros e a limpeza inicial dos dados nulos:

- **Feature Engineering:** A coluna `features` foi criada pela concatenação de `overview` + `keywords` + `genres` + `tagline`.
- **Limpeza de Texto:** Foi aplicada uma função de remoção de caracteres não-ASCII (*e.g.*, acentos e caracteres latinos especiais) e transformação para minúsculas, garantindo que o texto da base fosse limpo e homogêneo.

A base final utilizada para análise (carga) resultou em **30.612 títulos** de alta qualidade e relevância.

3.3 Preparação da Query e Simetria

O texto de perfil de preferência do usuário (*Query*) é processado simetricamente à base de dados: é submetido à mesma função de limpeza (`remove_non_ascii`) antes de ser adicionado ao *Corpus*.

3.4 Vetorização e Parâmetros

O *Corpus* (Query + 30.612 Filmes) é transformado pela classe `TfidfVectorizer` com os seguintes parâmetros para otimizar o resultado:

- `stop_words='english'`: Remove palavras comuns do idioma que não possuem valor semântico.
- `lowercase=True`: Remove a distinção entre maiúsculas e minúsculas.
- `token_pattern=r'\b\w+\b'`: Garante a remoção de pontuação e considera apenas seqüências alfanuméricas como *tokens*.

3.5 Cálculo da Similaridade

A matriz de *cosine similarity* é calculada entre o **vetor da Query** e todos os **vetores dos filmes**, resultando em um *array* de pontuações de **S** (similaridade). O ranqueamento é feito ordenando os filmes por **S** em ordem decrescente (do mais semelhante para o menos semelhante).

4 Análise de Resultados

4.1 Teste Aplicado: Perfil de Super-Heróis

O teste foi realizado utilizando uma *Query* focada em filmes de ação de Super-Heróis, com alta repetição de termos-chave para garantir um vetor dominante.

Query: I am looking for a superhero action film with massive scale and a focus on team dynamics. The plot must involve powerful heroes uniting to fight a global threat or a cosmic villain. Key elements include spectacular visual effects, epic battles, and complex interconnected storylines within a shared universe. I prefer films about superpowers, advanced technology, and saving the world, mixed with humor and emotional stakes. The film should explore teamwork, sacrifice, and the burden of heroism.

4.2 Ranking de Recomendação (TOP 5)

O modelo gerou o seguinte ranqueamento, que valida a correlação semântica entre a *Query* e as descrições dos filmes:

Rank	Filme	Similaridade (S)	Ângulo (θ) (Graus)
1	Spider-Man: No Way Home	0.159903	80.798727
2	Zack Snyder's Justice League	0.155047	81.080503
3	Batman and Harley Quinn	0.133499	82.328149
4	Cyberworld - The future is now	0.131263	82.457394
5	Nirbhay	0.125340	82.799585

4.3 Discussão dos Resultados

O ranqueamento demonstra a eficácia do sistema:

- Os filmes de maior similaridade (Rank 1 e 2) são títulos proeminentes de Super-Heróis (*Spider-Man* e *Justice League*), que possuem alto conteúdo textual em relação aos termos *superhero*, *team dynamics* e *global threat*.
- O ranqueamento é preciso: o filme mais relevante para o gênero obteve o **S** mais alto (≈ 0.16), que corresponde ao **menor ângulo** ($\approx 80.80^\circ$), provando que seu vetor é o mais próximo do vetor de preferência do usuário no espaço vetorial.

5 Conclusão

O projeto validou com sucesso a implementação de um sistema de recomendação baseado em conteúdo utilizando a **Similaridade de Cosseno** e **TF-IDF**. O rigoroso processo de ETL e filtragem resultou em um Corpus otimizado de **30.612 títulos** consistentes e relevantes. A análise comprovou que a distância angular é uma métrica poderosa para mapear a proximidade semântica do perfil do usuário com o conteúdo fílmico, resultando em um sistema de recomendação funcional e coerente.